

Processamento de Linguagem Natural

Análise de Sentimentos baseada em aspectos Relatório 2

Equipe Responsável:

Anna Carolina Brito Santos Farias - 811448

João Arthur Miguel Ribeiro - 821605

Maristella Ramalho Rangel - 821055

Rodrigo Smith Rodrigues - 821172

Ronan Antonio Pereira Junior - 821626

Vitória Hilgert Tomasel - 821259

São Carlos, 03/07/2026

1. Tarefa Escolhida : Análise de Sentimentos	3
2. Dataset que será usado	3
2.1 Características do RePro	4
3. Modelagem do Problema	4
4. Estratégias usadas	4
3.1 Fine tuning	5
3.1.1 Recursos em língua portuguesa usados	5
3.1.2 Etapas de pré-processamento e as formas de representação empregadas	5
3.1.3 Separação treino, teste e validação	8
3.1.4 Configurações do Fine-Tuning	8
3.1.4 Dificuldades encontradas	9
3.2 Baseado em regras	9
5. Avaliação quantitativa	10
5.1 Estratégia 1: Fine tuning	10
5.2 Estratégia 2: Baseado em Regras	14
6. Análise Qualitativa	15
6.1 Estratégia 1: Fine tuning	15
6.2 Estratégia 2: Baseado em Regras	17
7. Comparação entre as Estratégias	17
8. Considerações finais	18
9. Referências	19

1. Tarefa Escolhida: Análise de Sentimentos

A Análise de Sentimentos (AS) é uma tarefa de Processamento de Linguagem Natural que utiliza técnicas computacionais para identificar, extrair e categorizar opiniões, emoções e sentimentos expressos em textos. O seu principal objetivo é transformar dados não estruturados, como publicações em redes sociais, resenhas de produtos e comentários em fóruns, em informações estruturadas que podem ser usadas para auxiliar tomada de decisões.

Dessa forma a AS pode ser aplicada em diversas áreas do conhecimento, como: por empresas para avaliar as opiniões de clientes sobre seus produtos e serviços; na política para analisar a opinião pública sobre candidatos e partidos, a partir de comentários na internet; na educação para que instituições obtenham feedbacks de estudantes sobre disciplinas, professores, metodologias de ensino e ambientes virtuais de aprendizagem, etc.

Tipicamente, a análise de sentimentos é tratada como um problema de classificação de textos, considerando a sentença ou o texto completo, na qual as opiniões são organizadas em categorias de polaridade, como positiva, negativa ou neutra. O exemplo a seguir, apresentado por Santana e Freitas (2026), mostra uma instância de texto que é positivo, retirada do corpus ReLi : “impossível abandonar o livro pela metade”. Outro exemplo, dos mesmos autores, é uma instância de texto negativo retirada do corpus TwetSentBR: “Nunca fiquei tão bravo numa eliminação quanto hoje, Mas fazer o que, né? #HellsKitchenBR”.

Uma das variações da análise de sentimentos é a análise de sentimentos baseada em aspecto. Nesse tipo de abordagem, a polaridade é atribuída a cada aspecto específico de uma entidade (produtos, serviços, empresas, pessoas etc), permitindo uma análise mais detalhada, em que os aspectos podem corresponder a características, atributos ou componentes da entidade analisada.

No exemplo a seguir, retirado do dataset escolhido, o aspecto “produto” recebe polaridades positiva e negativa, ou seja, existem elementos com conotação positiva e outros com conotação negativa referentes ao mesmo aspecto, em um mesmo review: “A história é muito boa, porém o autor "enrolou" um pouco no meio do livro”. Neste outro exemplo, os aspectos “entrega” e “produto” recebem polaridade positiva : “Entrega rápida, produto muito bom Amei. Praticidade”.

A análise de sentimento no nível de aspecto é comumente usada em corpora de avaliação de produtos ou serviços, onde os usuários podem expressar diferentes sentimentos, com diferentes polaridades, sobre várias características ou aspectos (como ilustrado nos exemplos). Por isso, foi a abordagem escolhida para o projeto.

2. Dataset que será usado

O dataset utilizado será o [*RePro: A Benchmark Dataset for Opinion Mining for Brazilian Portuguese*](#) (DOS SANTOS SILVA et al., 2024). O RePro (REview of PROducts) é um dataset voltado para a mineração de opinião em português brasileiro, ele foi criado com base nos dados da e-commerce brasileira Americanas S.A. O seu objetivo principal é fornecer um recurso valioso para tarefas relacionadas à análise de sentimento e modelagem de tópicos no contexto de avaliações de produtos de e-commerce em português brasileiro.

2.1 Características do RePro

O dataset é composto por 10.003 avaliações de produtos, abrangendo diversas categorias, como Celulares e Smartphones (1.526 avaliações), Eletroportáteis (836), Beleza e Perfumaria (696), Utilidades Domésticas (625) e Móveis (610), entre outras.

Cada instância do dataset reúne informações sobre o produto avaliado: identificador (*product_id*), nome (*product_name*), marca (*product_brand*) e categoria (*site_category_lv1* e *site_category_lv2*), bem como o conteúdo da avaliação em si, composto por título (*review_title*) e corpo do texto (*review_text*). Complementam o registro a nota geral atribuída pelo consumidor (*overall_rating*), em escala de 1 a 5 estrelas, e a indicação de recomendação do produto a terceiros (*recommend_to_a_friend*). Além disso, informações demográficas do avaliador também estão presentes, como gênero, estado e ano de nascimento.

As avaliações são anotadas em dois níveis:

- **Tópico:** identifica o aspecto abordado no texto, podendo ser PRODUTO (7.822 ocorrências), ENTREGA (3.110), OUTROS (2.356), CONDIÇÕES DE RECEBIMENTO (1.711), ANÚNCIO (874) e INADEQUADA (411). Um mesmo aspecto pode ter mais de uma polaridade, **caracterizando uma anotação multirrótulo**. No dataset, cada tópico possui uma coluna binária correspondente (ex.: PRODUTO, ENTREGA, ANUNCIO), com valor 1 se o tópico está presente na avaliação e 0 caso contrário.
- **Polaridade:** indica o sentimento expresso em relação a cada tópico identificado, podendo ser POSITIVO, NEGATIVO ou NEUTRO.

Como é possível perceber com a gama de dados do dataset, o RePro destaca-se como um conjunto de dados voltado para tarefas de Análise de Sentimentos em português, oferecendo anotações detalhadas de tópico e polaridade que permitem o desenvolvimento e a avaliação de modelos para o domínio de avaliações de produtos no contexto do e-commerce brasileiro.

3. Modelagem do Problema

Considerando que em uma avaliação no dataset RePro um mesmo aspecto pode ter mais de uma polaridade, como ilustrado na seção 1, a tarefa de Análise de Sentimentos Baseada em Aspecto (ABSA) configura-se nesse projeto como um **problema de classificação multirrótulo**. Assim, uma dada entrada pode ter mais de uma classe/rótulo como saída.

4. Estratégias usadas

A tarefa de análise de sentimentos baseada em aspectos pode ser abordada por meio de diferentes estratégias computacionais. Nesta seção, são apresentadas as abordagens utilizadas no projeto: o fine-tuning de modelos de linguagem pré-treinados e a abordagem baseada em regras léxicas.

3.1 Fine tuning

3.1.1 Recursos em língua portuguesa usados

Para o contexto do trabalho, que utiliza dados em português brasileiro, utilizamos o BERTimbau, um modelo BERT pré treinado em um grande corpus de dados no idioma. O BERTimbau está disponível em duas versões, base e large, e demonstrou desempenho superior ao mBERT (modelo multilíngue) em diversas tarefas de PLN em português. A opção pelo modelo monolíngue se justifica pela observação consistente na literatura de que modelos pré-treinados na língua alvo tendem a superar os modelos multilíngues nas tarefas correspondentes (Souza et al, 2020). Além disso, usamos a versão base.

3.1.2 Etapas de pré-processamento e as formas de representação empregadas

Remoção das instâncias cujo tópico é INADEQUADA: consistem em instâncias nas quais o título ou texto da avaliação é formado em grande parte por sinais de pontuação, caracteres especiais, etc. Assim, não é possível extrair informações dessas avaliações (já que o texto não é opinativo de fato). Foram removidas 411 instâncias. Um exemplo é:

título:

review:gdssdfhhbcxx...

Junção dos campos review title e review text para gerar o texto de entrada: considerando que as palavras do título podem ajudar a entender os sentimentos expressos no texto de review, optamos por concatenar o título e o texto para formar o texto de entrada do modelo. Mas é preciso tomar alguns cuidados nessa junção porque mesmo que a avaliação não seja INADEQUADA, seu título pode ser.

Por isso, definimos que o título só será concatenado se:

- Não for só pontuação/caracteres especiais (sequências de asteriscos, pontos, etc.).
- Não for apenas um número (ex: 10, 0, etc)
- Tiver comprimento mínimo de 3 caracteres (excluindo coisas como '+ou-')

Assim, se o título respeitar esses critérios, retornamos como *input_text* : 'Título : {review_title}. Avaliação: {review_text}'. Caso contrário, retornamos apenas *Avaliação: {review_text}*.

Alguns exemplos de títulos que foram desconsiderados : "*", "***", ".", "+ou-".

Adaptação da entrada e saída para classificação multirrótulo: Para a classificação multirrótulo optamos por transformar o problema em uma tarefa de par de textos (Sentence-Pair Classification) acoplada a uma camada de classificação multirrótulo para os sentimentos.

Assim, a arquitetura do BERTimbau recebe como entrada o texto completo da avaliação (*input_text* gerado na etapa anterior) concatenado ao aspecto alvo através do token separador [SEP], gerando a seguinte estrutura de entrada:

None

[CLS] + input_text + [SEP] + Aspecto_Alvo + [SEP]

Assim, em vez de forçar o modelo a escolher uma única polaridade, a camada linear sobre o token [CLS] é configurada com **3 saídas binárias independentes**:

- **S_NEGATIVO**: 1 se houver sentimento negativo associado ao aspecto, 0 caso contrário.
- **S_NEUTRO**: 1 se houver neutralidade associada ao aspecto, 0 caso contrário.
- **S_POSITIVO**: 1 se houver sentimento positivo associado ao aspecto, 0 caso contrário.

Formação dos pares [texto, aspecto]: Para estruturar esses pares, que serão a entrada do modelo, definimos 5 casos, com base nos exemplos do dataset:

1. **Um aspecto e uma polaridade**: quando a avaliação ativa apenas um aspecto com uma única polaridade. Exemplos:

Review: Bom aparelho, rápido, ótima câmera, bateria com boa duração.

Aspecto: ['PRODUTO'].

Polaridades: ['POSITIVO'].

Review: AINDA NÃO RECEBI, ENTÃO NÃO POSSO AVALIAR. AINDA NÃO RECEBI, ENTÃO NÃO POSSO AVALIAR.

Aspecto: ['ENTREGA'].

Polaridades: ['NEUTRO'].

2. **Um único aspecto e mais de uma polaridade**: quando a avaliação ativa apenas um aspecto, mas apresenta mais de uma polaridade na lista. Exemplo:

Review: Bom produto, gostei. Só que a manga é muito grande eu vou ter que levar na costura para fechar um pouco do tamanho.

Aspecto: ['PRODUTO'].

Polaridades: ['NEGATIVO', 'POSITIVO'].

Assim, ['PRODUTO'] e ['NEGATIVO', 'POSITIVO'] é mantido como par único com rótulo binário positivo e negativo ativos : [1.0, 0, 1.0].

3. **Múltiplos aspectos com apenas uma polaridade**: Quando a lista contém múltiplos aspectos ativos, mas apenas uma única polaridade, assume-se que esse sentimento possui escopo global e propaga-se igualmente para todos os aspectos. Assim, a linha é duplicada para cada aspecto, herdando o mesmo rótulo de sentimento. Exemplos:

Review: RECOMENDO A TODOS PELA QUALIDADE DO APARELHO E RAPIDEZ NA ENTREGA.

Aspectos: ['ENTREGA', 'PRODUTO'].

Polaridade: ['POSITIVO']

Review: Entrega muito demorada e a caixa veio toda amassada.

Aspectos: ['CONDICOESDERECEBIMENTO', 'ENTREGA']

Polaridade: ['NEGATIVO']

Assim, cada exemplo acima gera duas entradas.

Os dois próximos casos geraram dúvidas com relação à interpretação do dataset. Após entrar em contato com o criador do RePro, ele afirmou que "a anotação do dataset RePro não foi construída em um nível de detalhamento granular que permita o pareamento exato entre aspecto e sentimento" e aconselhou **descartar os casos 4 e 5**, mantendo apenas as instâncias onde há apenas uma polaridade para tudo ou os casos em que a avaliação possui apenas um aspecto (casos 1 a 3).

4. **N aspectos e N polaridades:** Inicialmente assumimos que as polaridades são atribuídas aos aspectos de forma sequencial (primeiro aspecto tem a primeira polaridade, o segundo tem a segunda, etc). Mas isso não é válido para todas as instâncias deste caso. Exemplos:

Review: \$ 3.776,00? Por 8 copos de 300ml? E isso mesmo? Não posso acreditar deve ser erro de digitação. O produto São Otimos super recomendo, mas com esse valor não. Creio que em outro lugar deva estar mais barato. Tem que ter alguma explicação!

Aspectos: ['ANUNCIO', 'PRODUTO']

Polaridades: ['NEGATIVO', 'POSITIVO']

Review: A entrega foi dentro prazo o Produto muito fraco não gostei Não recomendo

Aspectos: ['ENTREGA', 'PRODUTO']

Polaridades: ['NEGATIVO', 'POSITIVO']

5. **Mais aspectos que polaridades, com mais de uma polaridade:** nos casos onde a quantidade de aspectos ativos difere da quantidade de polaridades (e há mais de um sentimento na lista), não dá para deduzir qual polaridade pertence a qual aspecto sem introduzir palpites ou dados artificiais. Exemplos:

Review: muito bom o produto sem nenhum amassado ou coisa do gênero o único problema foi a entrega que foi muito enrolada o rapaz que entregou se perdeu na minha cidade

Aspectos: ['CONDICOESDERECEBIMENTO', 'ENTREGA', 'PRODUTO']

Polaridades: ['NEGATIVO', 'POSITIVO']

Review: comprei meusmartfone,tudo ok entrga rapida mais com 3 meses deu um poblema na entrada do corregador ,nao consigo assistecia tecnica e nao nem o 0800 funciona pessima.

Aspectos: ['ENTREGA', 'OUTROS', 'PRODUTO']

Polaridades: ['NEGATIVO', 'POSITIVO']

Ao final desta etapa foram descartadas 597 instâncias do caso 4 e 346 instâncias do caso 5. Foram gerados 12980 pares [texto, aspecto], sendo 4168 do caso 1, 1029 do caso 2 e 7783 do caso 3.

3.1.3 Separação treino, teste e validação

Para esta etapa, separamos 80% dos dados para treino, 10% para validação e 10% para teste. Na separação foi necessário tomar o cuidado de deixar todos os aspectos referentes a um mesmo exemplo no dataset original em um mesmo grupo (treino, validação ou teste), isso evita vazamento de dados (o modelo ter um caso de teste cujo texto foi visto no treino) e enriquece a análise qualitativa (nos casos em que existem vários aspectos e uma polaridade, se um aspecto cair no conjunto de teste, os outros também cairão). Por exemplo, no dataset original temos:

Review: Colcha muito bonita e com a qualidade buddemeyer que todo mundo conhece. Já lavei umas 2 vezes e não mudou em nada o aspecto. Chegou perfeitamente a minha casa e dentro do prazo informado.

Aspectos: ['CONDICOESDERECEBIMENTO', 'ENTREGA', 'PRODUTO']

Polaridade: ['POSITIVO']

Ao formar os pares [texto, aspecto] na etapa anterior, esse exemplo gera três entradas. Nossa separação garante que as três entradas caiam em um mesmo conjunto. Para isso, fizemos as divisões tirando todos os textos duplicados e depois atribuímos entradas referentes a uma mesma review ao conjunto em que o primeiro tinha sido atribuído. Além disso, fixamos uma seed (42) para que a separação seja sempre a mesma caso o código seja executado novamente.

Ao final, ficamos com 10390 instâncias de treino, 1294 instâncias de validação e 1296 instâncias de teste.

3.1.4 Configurações do Fine-Tuning

O Fine-Tuning consiste em pegar o modelo pré-treinado BERTimbau e ajustar os seus pesos internos para se especializar na tarefa de ABSA. Como adotamos uma abordagem multirrótulo, usando pares [texto, aspecto], a camada de classificação adicionada sobre o token [CLS] possui 3 neurônios de saída correspondentes a [S_NEGATIVO, S_NEUTRO, S_POSITIVO]. Definimos o parâmetro *problem_type="multi_label_classification"*, o que instrui o Hugging Face a utilizar a função de perda de Entropia Cruzada Binária com Logits (BCEWithLogitsLoss) em vez da Cross-Entropy tradicional. Isso permite que **cada sentimento receba uma probabilidade independente entre 0 e 1**.

Etapa de validação: Para a validação, o modelo processa o conjunto de validação ao final de cada época de treinamento e calcula F1-Score Macro, que calcula o desempenho de cada classe isoladamente (usando F1) e faz uma média aritmética simples entre eles. No fim de todas as épocas, o Hugging Face carrega na memória os pesos da época que atingiu o maior F1-Score Macro na validação.

Etapa de treinamento: Para o treinamento, usamos as seguintes configurações~:

- *eval_strategy="epoch"* e *save_strategy="epoch"*: a validação será executada e os pesos do modelo serão salvos ao final de cada época;
- *learning_rate=2e-5*: usamos taxa de aprendizado de $2 \cdot 10^{-5}$;
- *per_device_train_batch_size=16* e *per_device_eval_batch_size=16*: define que tanto para treinamento quanto para validação, o tamanho do lote (batch) será de 16 entradas;
- *num_train_epochs=10*: treinamento foi executado por 10 épocas na GPU do Colab;
- *weight_decay=0.01*: usamos uma técnica de normalização para evitar overfitting;
- *seed=42*: fixamos a seed para garantir reprodutibilidade do modelo

3.1.4 Dificuldades encontradas

A principal dificuldade desta estratégia foi definir como formar os pares [texto, aspecto] a partir dos exemplos do dataset, principalmente para os casos 4 e 5, pois não sabíamos se existia alguma ordem na atribuição das polaridades aos aspectos que permitisse o processamento correto das instâncias. Essa dificuldade foi resolvida tirando dúvidas com a professora e com o Lucas, criador do dataset.

3.2 Baseado em regras

A abordagem baseada em regras léxicas consiste em identificar a polaridade de um texto a partir de palavras e expressões previamente associadas a sentimentos positivos, negativos ou neutros. Diferentemente das abordagens baseadas em transformers, esse método não depende de um processo de treinamento supervisionado, mas sim de um conjunto de regras linguísticas e de um léxico de sentimentos. Em geral, esses sistemas consideram a presença de palavras avaliativas, negações, pontuação e outros elementos textuais para estimar a polaridade de uma sentença. Apesar de mais simples que modelos neurais, abordagens baseadas em regras têm as vantagens de menor custo computacional e maior facilidade de implementação, não exigindo GPU nem etapa de treinamento.

O modelo base é o VADER (Valence Aware Dictionary and sEntiment Reasoner), proposto por Hutto e Gilbert (2014), um analisador de sentimentos baseado em regras e léxico originalmente desenvolvido para textos de redes sociais em inglês, que produz uma pontuação contínua de sentimento (*compound score*), posteriormente convertida em classes de polaridade.

Considerando que o dataset é composto por avaliações em português, foi utilizado o **LeIA (Léxico para Inferência Adaptada)**, desenvolvido por Almeida (2018). O LeIA é um

fork do léxico e da ferramenta VADER adaptado para textos em português, com suporte a emojis e foco em textos de mídias sociais, mas funcional em outros domínios. A biblioteca preserva a lógica de pontuação do VADER original, mas substitui o léxico por um dicionário próprio, traduzido e ajustado para expressões e construções linguísticas mais frequentes no português.

Pré-processamento: foi reaproveitado o mesmo conjunto de teste (`df_test`) formado na Estratégia 1, já com as etapas de remoção de instâncias INADEQUADA, junção de título e texto, e formação dos pares [texto, aspecto] (Casos 1, 2 e 3). Isso garante que as duas estratégias sejam avaliadas exatamente sobre as mesmas instâncias, tornando a comparação direta e justa.

Diferença importante em relação à Estratégia 1: enquanto o BERTimbau recebe o par [texto, aspecto] como entrada (por meio do token [SEP]), o LeIA não tem mecanismo para focar em um aspecto específico — ele calcula um único *compound score* sobre o texto_completo da avaliação, sem nenhuma informação sobre qual aspecto está sendo avaliado. Na prática, isso significa que **a mesma predição de sentimento é aplicada a todas as linhas de pares [texto, aspecto] que compartilham o mesmo texto de origem**, mesmo quando esses pares se referem a aspectos diferentes. Essa é uma limitação estrutural de métodos léxicos "puros": eles fazem análise de sentimento do texto como um todo, e não análise de sentimento por aspecto de fato.

O mapeamento do *compound score* para as classes seguiu os limiares convencionais do VADER/LeIA: POSITIVO se $\text{compound} \geq 0.05$, NEGATIVO se $\text{compound} \leq -0.05$, e NEUTRO no intervalo entre os dois.

Dificuldades encontradas: a principal dificuldade foi justamente a ausência de mecanismo para isolar o trecho do texto referente a um aspecto específico, o que gera erros sistemáticos em avaliações que tratam de múltiplos aspectos com sentimentos distintos (discutido em detalhe nas seções 5.2 e 6.2). Além disso, por gerar apenas uma predição por instância de texto (não multirrótulo), o método é estruturalmente incapaz de prever mais de uma polaridade simultânea para o mesmo aspecto (Caso 2).

5. Avaliação quantitativa

5.1 Estratégia 1: Fine tuning

A avaliação quantitativa foi dividida em duas etapas:

1. Análise Global: avaliamos o desempenho do modelo considerando todas as instâncias de teste. Para isso, fizemos uma análise para cada classe (NEGATIVO, NEUTRO, POSITIVO) e uma análise geral.

Para a análise por classe usamos as medidas clássicas de classificação: como precisão, revocação e F1-Score. Importante ressaltar que o modelo faz predições binárias

independentes para cada sentimento, mas definimos um **limiar de confiança de 70%** para considerar a predição.

Para avaliar o desempenho geral do modelo, usamos duas métricas, sendo uma específica para classificação multirrótulo.


- **Exact Match Ratio:** avalia a porcentagem de instâncias de teste em que o **modelo acertou o vetor de sentimentos inteiro**. Ex: se o gabarito era [1, 0, 0] e o modelo previu [1, 0, 1], é considerado um erro.
- **F1-Score Macro:** Calcula o F1-Score de cada um dos 3 sentimentos de forma independente e tira a média aritmética simples entre eles, pesando todas as classes de forma igual. (mesma medida usada para validação)

```
===== ANÁLISE QUANTITATIVA GLOBAL=====
```

	precision	recall	f1-score	support
NEGATIVO	0.99	0.97	0.98	644
NEUTRO	0.73	1.00	0.84	38
POSITIVO	0.99	0.99	0.99	731
micro avg	0.98	0.98	0.98	1413
macro avg	0.90	0.99	0.94	1413
weighted avg	0.98	0.98	0.98	1413
samples avg	0.98	0.98	0.98	1413

Exact Match Ratio Geral: 96.68%

O modelo atingiu Exact Match Ratio de 96.68%, ou seja, errou apenas 43 das 1296 instâncias de teste. Além disso, atingiu F1-Macro de 0.94.



Fazendo a análise por sentimento, observa-se inicialmente que o conjunto de teste apresenta um desbalanceamento entre as classes. Foram identificados 644 exemplos da classe NEGATIVO, 38 exemplos da classe NEUTRO e 731 exemplos da classe POSITIVO. Embora o conjunto de teste possua 1296 instâncias, a soma dos exemplos das classes totaliza 1413 ocorrências de rótulos, pois o problema é de classificação multirrótulo, permitindo que uma mesma avaliação seja associada simultaneamente a mais de um sentimento.

Em cenários com classes desbalanceadas, a acurácia isoladamente pode fornecer uma visão distorcida do desempenho do modelo, uma vez que classes majoritárias tendem a dominar o resultado final. Por isso, métricas como precisão, revocação/coertura e F1-Score são mais adequadas para a análise individual das classes.

Para a classe NEGATIVO, o modelo alcançou precisão de 99%, revocação de 97% e F1-Score de 98%. A precisão alta indica que, quando o modelo prevê a presença de sentimento negativo, essa previsão está quase sempre certa. Já a revocação um pouco menor demonstra que uma pequena parcela das avaliações negativas não foi identificada. O F1-Score próximo de 1 mostra um equilíbrio entre essas métricas.

A classe NEUTRO é a menos representada no conjunto de teste. Para essa classe, o modelo obteve revocação de 100%, precisão de 73% e F1-Score de 84%. A revocação máxima indica que todos os exemplos neutros presentes no conjunto de teste foram corretamente identificados. Entretanto, a precisão inferior às demais classes mostra que o modelo previu incorretamente muitos exemplos como neutros. Além disso, o número reduzido de exemplos torna as métricas mais sensíveis a pequenas variações.

A classe POSITIVO é a mais frequente no conjunto de teste. Nessa classe, o modelo apresentou desempenho praticamente perfeito, alcançando 99% de precisão, 99% de revocação e 99% de F1-Score. Esses resultados indicam alta capacidade tanto para identificar corretamente avaliações positivas quanto para evitar classificações incorretas dessa categoria.

De forma geral, os resultados demonstram que o modelo apresenta desempenho consistente para as classes NEGATIVO e POSITIVO, ambas com F1-Score próximo de 1. A principal dificuldade está associada à classe NEUTRO, que possui uma quantidade significativamente menor de exemplos e cuja natureza pode ser mais ambígua, dificultando sua distinção em relação aos demais sentimentos.

Já analisando as métricas de agregação, observa-se que o **micro avg** apresenta F1-Score de 0.98, calculado de forma global ao agregar todas as predições individuais de cada rótulo em um único conjunto. Por ponderar igualmente cada ocorrência de rótulo, essa métrica tende a refletir o desempenho nas classes majoritárias (NEGATIVO e POSITIVO), o que explica seu valor elevado e consistente com os resultados individuais dessas classes.

O **macro avg**, por sua vez, calcula a média aritmética simples entre as três classes, tratando-as com igual peso independentemente do número de exemplos. Isso explica a discrepância observada: a precisão macro de 0.90 é puxada para baixo pela precisão inferior da classe NEUTRO (0.73), enquanto a revocação macro de 0.99 é elevada pela revocação perfeita dessa mesma classe (1.00). Esse comportamento evidencia como a classe minoritária NEUTRO impacta de forma desproporcional as médias não ponderadas.

O **weighted avg** corrige esse efeito ao ponderar cada classe pelo seu número de exemplos (support). Como NEGATIVO e POSITIVO dominam o conjunto de teste (644 e 731 exemplos, respectivamente, frente a apenas 38 da classe NEUTRO), as métricas ponderadas ficam muito próximas do micro avg (0.98), refletindo novamente o desempenho excelente nas classes majoritárias.

Por fim, o **samples avg** é uma métrica específica para classificação multirrótulo: calcula precisão, revocação e F1-Score para cada instância individualmente, considerando o vetor completo de rótulos, e depois tira a média entre todas as instâncias. O valor de 0.98 indica que, na grande maioria dos casos, o modelo acerta o conjunto completo de polaridades atribuídas a um dado par [texto, aspecto], o que é coerente com o Exact Match Ratio de 96.68% obtido.

2. Avaliação por caso: separamos as instâncias de cada um dos três casos mantidos (1 a 3) e usamos as mesmas medidas da etapa anterior.

Caso 1: Um aspecto e uma polaridade: é composto por 394 exemplos, apresentando Exact Match Ratio de 95,94% (16 erros) e F1-Score Macro de 94,67%. Por ser o caso mais simples, uma única polaridade por instância, o Exact Match Ratio equivale à acurácia direta por instância, o que torna o resultado ainda mais expressivo.

A classe NEGATIVO obteve 96% de F1-Score, demonstrando alta capacidade de identificação desse sentimento. A classe NEUTRO, embora possua apenas 16 exemplos, apresentou 100% de revocação e 80% de precisão: todos os exemplos neutros foram detectados, mas o modelo também classificou alguns exemplos não-neutros como neutros (falsos positivos). Esse comportamento pode indicar que o modelo tende a recorrer à polaridade neutra como "saída de segurança" em textos com sentimento menos explícito. Já a classe POSITIVO alcançou desempenho praticamente perfeito, com 99% de precisão, revocação e F1-Score, refletindo tanto a abundância de exemplos dessa classe quanto a clareza dos padrões linguísticos associados a avaliações positivas.

Caso 2: Um aspecto e mais de uma polaridade: é composto por 117 pares de avaliações e apresentou Exact Match Ratio de 88,03% (14 erros) e F1-Score Macro de 64,61%, os menores valores para essas medidas considerando os 3 casos. Isso demonstra que o modelo teve maior dificuldade em lidar com exemplos nos quais o aspecto possuía mais de uma polaridade (positiva e negativa).

O modelo atingiu precisão de 100% nas classes POSITIVO e NEGATIVO, indicando que todos os casos em que o modelo previu essas classes estavam corretos. Vale notar que não foram encontrados exemplos da classe neutra nesse caso, pois não existem avaliações que possuem as polaridades ['POSITIVO', 'NEUTRO'] ou ['NEGATIVO', 'NEUTRO']. Além disso, o modelo tem uma cobertura menor para a classe NEGATIVO, indicando maior dificuldade em detectar esse sentimento em exemplos que possuem também polaridade positiva.

Caso 3: Múltiplos aspectos com apenas uma polaridade: o caso 3 apresentou os melhores resultados gerais, mas possui a maior quantidade de exemplos, com 785. Obteve Exact Match Ratio de 98,34% (13 erros) e F1-Score Macro de 93,25%.

A classe NEGATIVO obteve 99% de F1-Score, enquanto a classe POSITIVO também alcançou 99%, evidenciando ótima capacidade de classificação. A classe NEUTRO, apesar de possuir apenas 22 exemplos, apresentou 100% de revocação, 69% de precisão e 81% de F1-Score, padrão semelhante ao observado no Caso 1, com todos os exemplos neutros identificados, mas com a presença de falsos positivos. Isso reforça que a dificuldade com a classe NEUTRO é estrutural e não específica a um caso: decorre da escassez de exemplos e da natureza intrinsecamente ambígua de textos neutros, que podem se assemelhar tanto a avaliações positivas quanto negativas.

De modo geral, o modelo continua tendo maior dificuldade com a classe NEUTRO independente do caso, o que provavelmente ocorre por ser a classe com menos exemplos. Entretanto, o caso 2 é o que o modelo apresenta maior dificuldade, atingindo precisão macro de 67% e revocação macro de 63%, indicando presença maior de falsos positivos e falsos negativos em relação aos outros casos. Isso mostra que, em muitos casos, o modelo deixa de atribuir uma das duas polaridades.

5.2 Estratégia 2: Baseado em Regras

Assim como na Estratégia 1, a avaliação foi feita sobre o mesmo conjunto de teste (1296 instâncias), permitindo comparação direta entre os métodos.

Análise Global: o LeIA atingiu Exact Match Ratio de 78,09% (284 erros de 1296) e F1-Score Macro de 0,63.

Por classe: NEGATIVO obteve precisão de 0,92, revocação de 0,73 e F1 de 0,82 (support 644); NEUTRO obteve precisão de 0,18, revocação de 0,21 e F1 de 0,20 (support 38); POSITIVO obteve precisão de 0,88, revocação de 0,89 e F1 de 0,88 (support 731). As médias de agregação foram: micro avg F1 0,83, macro avg F1 0,63, weighted avg F1 0,83 e samples avg F1 0,84.

A classe NEUTRO apresenta o desempenho mais fraco de longe, com precisão de apenas 0,18. Isso sugere que o LeIA classifica como neutro muitos textos que, no gabarito, têm polaridade definida — provavelmente textos curtos, ambíguos ou sem vocabulário fortemente carregado, cujo compound score cai dentro da faixa neutra por padrão, mesmo quando a avaliação humana identificou sentimento presente.

Matrizes de confusão por classe:

===== DETALHAMENTO POR CLASSE (GLOBAL) =====				
	precision	recall	f1-score	support
NEGATIVO	0.92	0.73	0.82	644
NEUTRO	0.18	0.21	0.20	38
POSITIVO	0.88	0.89	0.88	731
micro avg	0.87	0.80	0.83	1413
macro avg	0.66	0.61	0.63	1413
weighted avg	0.88	0.80	0.83	1413
samples avg	0.87	0.83	0.84	1413

Observa-se que a classe NEGATIVO concentra o maior número de falsos negativos (171 de 644 casos positivos), ou seja, o LeIA frequentemente deixa de identificar sentimento negativo presente no gabarito. Já a classe POSITIVO apresenta 91 falsos positivos, indicando tendência do método a superestimar a presença de sentimento positivo — consistente com o padrão observado na análise qualitativa, em que palavras positivas isoladas dominam o compound score mesmo em textos com conteúdo negativo relevante.

Avaliação por caso:

===== RELATÓRIO DE DESEMPENHO: LeIA (VADER-PT) =====				
Cenário	Natureza	Amostras	Exact Match Ratio (%)	F1-Score Macro (%)
Caso 1	Sentimento Único	394	85.280000	66.350000
Caso 2	Múltiplos Sentimentos	117	0.000000	43.750000
Caso 3	Múltiplos Aspectos	785	86.110000	64.240000
GLOBAL	Dataset de Teste Total	1296	78.090000	63.150000

O resultado mais expressivo é o Exact Match Ratio de 0% no Caso 2, decorrente de uma limitação teórica do método: como o LeIA gera um único rótulo escalar por texto, ele é estruturalmente incapaz de prever duas polaridades simultâneas para a mesma instância — diferente do BERTimbau, que tem uma camada de saída multirrótulo com neurônios independentes. Assim, toda instância do Caso 2 é necessariamente contabilizada como erro de correspondência exata, mesmo quando o LeIA acerta parcialmente uma das duas polaridades presentes.

6. Análise Qualitativa

6.1 Estratégia 1: Fine tuning

Caso 1: um aspecto e uma polaridade

Ex1:

id_teste_sequencial	caso	aspecto	texto_original	gabarito_real	predicao_modelo	confianca_negativo	confianca_neutro	confianca_positivo
4	122	Caso 1 PRODUTO	Título: Avaliação. Avaliação: Achei que supriria minhas necessidades com maior eficiência.	[NEGATIVO]	[NEUTRO]	0.018405	0.988712	0.000732

O modelo atribuiu polaridade neutra ao aspecto PRODUTO, com confiança de 0.988712, quando o esperado era negativo. Isso pode ser devido ao texto ser curto e não conter nenhum marcador léxico de negatividade explícita. A polaridade negativa só pode ser inferida pela estrutura contrafactual "Achei que supriria", que implica expectativa não atendida. Sem adjetivos ou expressões negativas diretas, o modelo classificou o exemplo como neutro com alta confiança, sugerindo que aprendeu a tratar textos sem sinal léxico claro como pertencentes a essa classe.

Ex2:

id_teste_sequencial	caso	aspecto	texto_original	gabarito_real	predicao_modelo	confianca_negativo	confianca_neutro	confianca_positivo
11	164	Caso 1 PRODUTO	Título: Bom custo benefício. Avaliação: Bom custo benefício na cafeteira, só que ela é menor do que eu imaginava. Mas muito boa.	[POSITIVO]	[NEGATIVO, POSITIVO]	0.998066	0.000626	0.999409

Nesse exemplo, o modelo atribuiu também polaridade negativa ao PRODUTO, com confiança de 0.998066. De fato, parece existir conotação negativa no trecho "só ela é menor do que eu imaginava", o que apontar possível inconsistência na anotação.

Ex3:

id_teste_sequencial	caso	aspecto	texto_original	gabarito_real	predicao_modelo	confianca_negativo	confianca_neutro	confianca_positivo
32	711	Caso 1 PRODUTO	Título: Opinião. Avaliação: A tá que esses pincéis são originais na MAC por esse preço?! Ahámmm.... Vão achando!!	[NEGATIVO]	[NEUTRO]	0.001174	0.99951	0.00124

Nesse exemplo o modelo não conseguiu capturar a polaridade negativa do PRODUTO e atribuiu polaridade neutra com confiança de 0.99951. O texto de review contém **sarcasmo**, que não foi aprendido/capturado pelo modelo.

Caso 2: Um aspecto e mais de uma polaridade

Ex1:

id_teste_sequencial	caso	aspecto	texto_original	gabarito_real	predicao_modelo	confianca_negativo	confianca_neutro	confianca_positivo
35	875	Caso 2 PRODUTO	Título: Péssima qualidade do som. Avaliação: Comprei esse produto por ter uma caixinha pequena de som, como bem menos potencia RMS (5W) e ser desta marca... e ser muito boa. Fiz a compra e, assim que ligo, minha surpresa - som de péssima qualidade! Com abafado, agudos muito acentuados... e acustica/caixa de som com emissão bem ruim. Fiz a devolução no ato!	[NEGATIVO, POSITIVO]	[NEGATIVO]	0.999737	0.000367	0.000501

O modelo não atribui polaridade positiva ao PRODUTO. O trecho "e ser muito boa" pode ter levado à anotação da polaridade positiva. Entretanto, se refere ao que era esperado pela pessoa no ato da compra, mas não foi atendido. Isso fica evidente no trecho "Fiz a compra e, assim que ligo, minha surpresa - som de péssima qualidade!". Possivelmente, o modelo não identificou conotação positiva nesse trecho.

Ex2:

id_teste_sequencial	caso	aspecto	texto_original	gabarito_real	predicao_modelo	confianca_negativo	confianca_neutro	confianca_positivo
5	128	Caso 2 PRODUTO	Título: Avaliação celular. Avaliação: Um aparelho regular diante dos mais sofisticados. Porém, para usuários não tão exigentes quanto a velocidade, é o ideal diante ao seu custo.	[NEGATIVO, POSITIVO]	[POSITIVO]	0.030792	0.000222	0.999886

O modelo não conseguiu capturar a polaridade negativa do PRODUTO. Isso pode ter ocorrido porque no texto de review a conotação negativa não está explícita, com adjetivos que indiquem diretamente um sentimento negativo em relação ao produto, por exemplo. Palavras como “ideal” e “regular” podem ter contribuído para identificação da polaridade positiva.

Caso 3: Múltiplos aspectos com apenas uma polaridade

Ex:

O exemplo original do dataset tinha 3 aspectos [ANUNCIO, PRODUTO, OUTROS], todos como polaridade negativa. Esse exemplo gerou três entradas, que caíram no conjunto de teste.

...				texto_completo	aspecto	caso_origem	labels
856	Título: Propaganda enganosa ou falta de controle de qualidade. Avaliação: As panelas grudam o alimento sem e com gordura, que decepção!!!! É uma tefal melhorada, acho que não passou pelo controle de qualidade.No vídeo é maravilhoso, mas na realidade não é assim, não entrega o que comercializa, cozinhar sem gordura sem o alimento grudar. Cancelei o pedido e pedi a retirada dos produtos				ANUNCIO	Caso 3	[1.0, 0.0, 0.0]
857	Título: Propaganda enganosa ou falta de controle de qualidade. Avaliação: As panelas grudam o alimento sem e com gordura, que decepção!!!! É uma tefal melhorada, acho que não passou pelo controle de qualidade.No vídeo é maravilhoso, mas na realidade não é assim, não entrega o que comercializa, cozinhar sem gordura sem o alimento grudar. Cancelei o pedido e pedi a retirada dos produtos				OUTROS	Caso 3	[1.0, 0.0, 0.0]
858	Título: Propaganda enganosa ou falta de controle de qualidade. Avaliação: As panelas grudam o alimento sem e com gordura, que decepção!!!! É uma tefal melhorada, acho que não passou pelo controle de qualidade.No vídeo é maravilhoso, mas na realidade não é assim, não entrega o que comercializa, cozinhar sem gordura sem o alimento grudar. Cancelei o pedido e pedi a retirada dos produtos				PRODUTO	Caso 3	[1.0, 0.0, 0.0]

id_teste_sequencial	caso	aspecto	texto_original	gabarito_real	predicao_modelo	confianca_negativo	confianca_neutro	confianca_positivo
34	858	Caso 3 PRODUTO	Título: Propaganda enganosa ou falta de controle de qualidade. Avaliação: As panelas grudam o alimento sem e com gordura, que decepção!!!! É uma tefal melhorada, acho que não passou pelo controle de qualidade.No vídeo é maravilhoso, mas na realidade não é assim, não entrega o que comercializa, cozinhar sem gordura sem o alimento grudar. Cancelei o pedido e pedi a retirada dos produtos	[NEGATIVO]	[NEGATIVO, POSITIVO]	0.999726	0.000156	0.889337

O modelo acertou a polaridade dos aspectos ANUNCIO e OUTROS, mas atribuiu polaridade positiva ao PRODUTO, com confiança de 0.889337. Um trecho que pode ter contribuído para isso é "No vídeo é maravilhoso", no qual o adjetivo pode ter sido visto em muitos exemplos positivos durante o treinamento. Entretanto, esse trecho é seguido por "mas na realidade não é assim", em que as palavras “mas” e “não” deixam evidente a "mudança de sentido". Isso não foi capturado pelo modelo.

6.2 Estratégia 2: Baseado em Regras

Caso 1: um aspecto e uma polaridade

Ex1:

ID 982, aspecto PRODUTO — Review: "Sou fã!. Avaliação: É o único produto que 'salva' meu cabelo, pois nado 3 vezes por semana!"

Gabarito: [POSITIVO] | Predição LeIA: [NEUTRO]

O sentimento positivo nesse texto é expresso de forma implícita, por meio de uma relação de dependência e afeto pelo produto ("sou fã", "salva meu cabelo"), sem o uso de adjetivos avaliativos explícitos que constem no léxico do LeIA (como "ótimo", "excelente", "bom"). Sem esse vocabulário direto, o compound score ficou dentro da faixa neutra, levando o modelo a não identificar a polaridade correta — um padrão semelhante ao observado no BERTimbau para textos sem marcador léxico claro (seção 6.1, Caso 1, Ex1), embora por mecanismos distintos: o BERTimbau aprende esse padrão a partir dos dados de treino, enquanto o LeIA depende exclusivamente da presença de termos já catalogados em seu dicionário.

Caso 2: um aspecto e mais de uma polaridade

Ex1:

ID 35, aspecto PRODUTO — Review: "Título: Achei bom.. Avaliação: Ele é bom e pelo preço não esperava nada muito além do que achei. Pontos negativos é que machuca muito na

hora de fazer..."

Gabarito: [NEGATIVO, POSITIVO] | Predição LeIA: [POSITIVO]

Como o LeIA calcula um único compound score agregando todo o texto, o termo positivo "bom" (repetido duas vezes) predominou sobre o trecho negativo "pontos negativos é que machuca muito", resultando em uma predição exclusivamente positiva. Esse exemplo ilustra diretamente a limitação estrutural do método nesse caso: por gerar apenas um rótulo escalar por instância, o LeIA nunca conseguiria acertar completamente exemplos desse caso.

Caso 3: múltiplos aspectos com apenas uma polaridade

Ex:

ID 12 e ID 13, aspectos CONDICOESDERECEBIMENTO e OUTROS, respectivamente — Review: "Título: A TAMPÁ VEIO TODA QUEBRADA. Avaliação: ATE O PRESENTE MOMENTO NENHUMA DAS LOJAS TOMARAM AS DEVIDAS PROVIDÊNCIAS. O FOGÃO VEIO COM A TAPA CHEIA DE CACOS DE VIDROS, TOTALMENTE QUEBRADA. [...] O MOTORISTA LARGOU DE QUALQUER JEITO E DISSE ESTAR COM PRESSA [...] DEIXOU O FOGÃO E FORAM EMBORA. ASSIM QUE TUDO ESTIVER RESOLVIDO DAREI MINHA AVALIAÇÃO NOVAMENTE."

Gabarito: [NEGATIVO] para ambos os aspectos | Predição LeIA: [POSITIVO] para ambos os aspectos

Neste exemplo, apesar de o texto ser fortemente negativo (relato de produto quebrado, falta de solução da loja, atendimento inadequado do motorista), o LeIA classificou-o como positivo. Uma hipótese é que a palavra "resolvido", ao final do texto ("assim que tudo estiver resolvido..."), tenha pesado positivamente no cálculo do compound score. Além disso, esse caso evidencia de forma direta a limitação já discutida na seção 3.2: como o LeIA não recebe o aspecto como parte da entrada, ele gera exatamente a mesma predição (POSITIVO) para as duas linhas de teste correspondentes ao mesmo texto, mesmo elas se referindo a aspectos distintos.

De modo geral, os erros do LeIA nos três casos seguem um padrão consistente: o método tende a ser enganado por palavras isoladas de polaridade oposta ao sentimento predominante do texto e tem dificuldade em captar sentimento expresso sem vocabulário avaliativo direto. Essas limitações estão diretamente ligadas à natureza do método — análise léxica pura, sem compreensão contextual ou sintática.

7. Comparação entre as Estratégias

Síntese comparativa:

Cenário	BERTimbau (Estratégia 1)	LeIA (Estratégia 2)	Δ
Global	96,68%	78,09%	+18,59 p.p. para BERT
Caso 1	95,94%	85,28%	+10,66 p.p. para BERT
Caso 2	88,03%	0,00%	inviabilidade estrutural do léxico
Caso 3	98,34%	86,11%	+12,23 p.p. para BERT

Comparação das matrizes de confusão: colocando as duas matrizes lado a lado, os números por classe reforçam o padrão observado nas métricas agregadas:

Classe	Falsos Negativos (BERT)	Falsos Negativos (LeIA)	Falsos Positivos (BERT)	Falsos Positivos (LeIA)
NEGATIVO	21	171	9	40
NEUTRO	0	30	14	36
POSITIVO	9	83	5	91

O contraste mais evidente está na classe NEGATIVO: o LeIA comete 171 falsos negativos contra apenas 21 do BERTimbau — oito vezes mais casos em que sentimento negativo presente no gabarito não é identificado. Isso indica que grande parte da sinalização negativa nas avaliações do RePro não está em vocabulário explicitamente negativo (que o léxico consegue captar), mas em construções mais sutis — sarcasmo, expectativa frustrada, reclamações indiretas — que exigem compreensão contextual, algo que o BERTimbau adquire durante o fine-tuning e o LeIA não tem como capturar.

Já na classe POSITIVO, o LeIA apresenta 91 falsos positivos contra apenas 5 do BERTimbau, sugerindo a tendência oposta: o léxico tende a superestimar positividade, provavelmente por dar peso decisivo a palavras isoladas de conotação positiva mesmo quando o restante do texto é predominantemente negativo (comportamento observado diretamente nos exemplos qualitativos da seção 6.2, como o caso do fogão quebrado em que o termo "resolvido" parece ter revertido o score para positivo).

O colapso do léxico no Caso 2: a falha do LeIA nesse caso (EMR de 0%) não é um erro de implementação, mas uma limitação teórica de sistemas baseados em dicionários de polaridade, que geram um único valor escalar por texto — mapeável para apenas uma classe. O BERTimbau, com sua camada de saída multirrótulo, consegue prever que uma mesma frase é simultaneamente positiva e negativa.

A superioridade contextual no Caso 3: nesse caso, onde há múltiplos aspectos, o BERTimbau utiliza o token separador [SEP] para focar a atenção no aspecto relevante — por

exemplo, no input [CLS] O design é lindo mas a bateria é ruim [SEP] BATERIA, o mecanismo de atenção consegue dar menos peso ao termo "lindo". O LeIA, por processar a frase inteira sem essa informação, soma as polaridades de todos os termos indiscriminadamente, podendo neutralizar ou inverter o resultado esperado para um aspecto específico.

Trade-off custo computacional vs. desempenho: enquanto o BERTimbau exige GPU e uma etapa de treinamento (fine-tuning), o LeIA é uma solução zero-shot, que roda instantaneamente em qualquer CPU sem nenhum treinamento prévio. Para aplicações que não exigem granularidade por aspecto — por exemplo, uma triagem inicial de sentimento geral de uma avaliação —, o método léxico ainda é uma alternativa viável de baixo custo. Já para análise de sentimento baseada em aspecto de fato, os resultados deste trabalho indicam que o fine-tuning de um modelo Transformer é necessário para capturar a granularidade exigida pela tarefa.

8. Considerações finais

Este trabalho permitiu comparar, na prática, duas abordagens bastante distintas para Análise de Sentimentos Baseada em Aspecto: o fine-tuning de um modelo Transformer (BERTimbau) e um método baseado em léxico e regras (LeIA). Os resultados confirmaram a expectativa inicial de que o fine-tuning seria superior como estratégia principal, mas o método baseado em regras se mostrou um baseline valioso, evidenciando de forma clara *por que* essa superioridade existe — não apenas quantificando a diferença de desempenho (EMR de 96,68% contra 78,09%), mas explicando sua origem: a capacidade do BERTimbau de focar no aspecto relevante via token [SEP] e de prever múltiplas polaridades simultaneamente, algo estruturalmente inacessível a um método que resume o texto inteiro a um único score.

Do ponto de vista de aprendizado do grupo, a maior dificuldade do projeto não foi de implementação, mas de **interpretação do dataset**: decidir como formar os pares [texto, aspecto] a partir de anotações que nem sempre permitem um pareamento exato entre aspecto e sentimento exigiu contato direto com o criador do RePro e discussão em grupo, reforçando a importância de validar suposições sobre os dados antes de construir qualquer pipeline em cima delas.

Outro aprendizado importante veio da análise qualitativa: em ambas as estratégias, os erros se concentraram em casos que exigem compreensão contextual — sarcasmo, expectativa frustrada, sentimento implícito — e não simples reconhecimento de vocabulário. Isso reforça que, para tarefas de ABSA em domínios com linguagem informal como avaliações de e-commerce, modelos com mecanismo de atenção têm vantagem estrutural sobre métodos puramente lexicais, embora estes últimos continuem sendo úteis como alternativa de baixo custo em cenários que não exigem granularidade por aspecto.

9. Referências

- Santana, B. S. e Freitas, L. A. d. (2026). PLN em redes sociais. In Caseli, H. M. e Nunes, M. G. V., editors, *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*, volume 3, book chapter 16. BPLN, 4 edition. ISBN 978-65-02-00167-7. URL <https://brasileiraspln.ufscar.br/livro-pln-4ed-vol3/aplicacoes-e-dominios/cap-redes-sociais/cap-redes-sociais.html>. Acesso em: 19 mai. 2026.
- Devlin, J., Chang, M.-W., Lee, K. e Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In Burstein, J., Doran, C. e Solorio, T., editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota. Association for Computational Linguistics. URL <https://aclanthology.org/N19-1423/>. Acesso em: 27 mai. 2026.
- Souza, F., Nogueira, R. e Lotufo, R. (2020). BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In Cerri, R. e Prati, R. C., editors, *Intelligent Systems. 9th Brazilian Conference on Intelligent Systems, BRACIS 2020*, pages 403–417. Springer, Cham. Lecture Notes in Computer Science, vol. 12319. URL https://dl.acm.org/doi/10.1007/978-3-030-61377-8_28. Acesso em: 27 mai. 2026.
- dos Santos Silva, L. N., Real, L., Zandavalle, A. C. B., Rodrigues, C. F. G., da Silva Gama, T., Souza, F. G., & Zaidan, P. D. S. (2024). *RePro: a benchmark for Opinion Mining for Brazilian Portuguese. Proceedings of the 16th International Conference on Computational Processing of Portuguese*, 432–440.
- Hutto, C. J. e Gilbert, E. (2014). VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text. In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 8, pages 216–225. AAAI Press. URL <https://ojs.aaai.org/index.php/ICWSM/article/view/14550>. Acesso em: 27 mai. 2026.
- Almeida, R. J. A. (2018). LeIA - Léxico para Inferência Adaptada. GitHub repository. URL <https://github.com/rafjaa/LeIA>. Acesso em: 21 jun. 2026.